




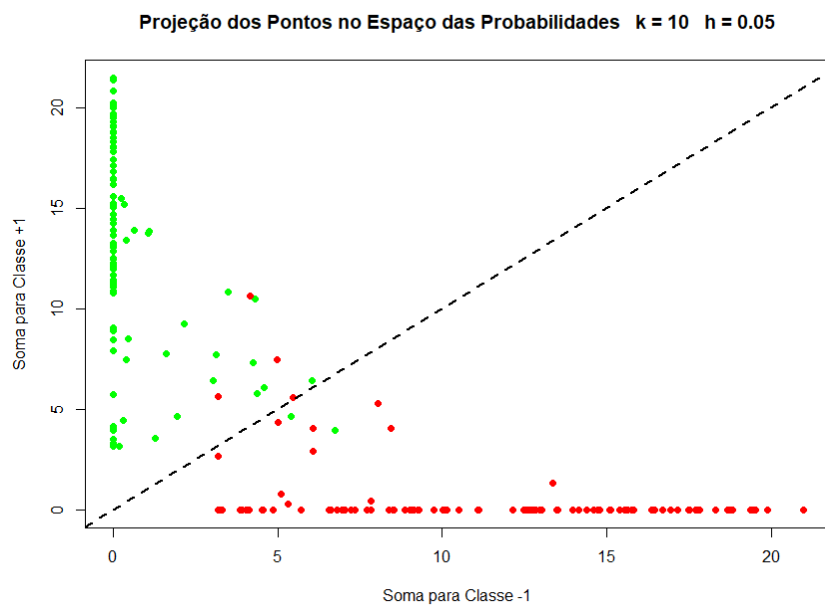



Disciplina de Reconhecimento de Padrões - 2025/01  
Exercício 2 sobre KNN (K Nearest Neighbors) com Distâncias Ponderadas

Aluna: Raissa Gonçalves Diniz - 2022055823







### Análise dos resultados:

No modelo de classificação KNN com distância ponderada, os parâmetros  $k$  e  $h$  desempenham papéis fundamentais na forma como a decisão é tomada. O parâmetro  $k$  representa o número de vizinhos considerados para classificar um novo ponto, influenciando diretamente a suavidade da fronteira de decisão: valores altos tornam a separação entre classes mais suave, enquanto valores baixos resultam em uma fronteira mais detalhada, mas também mais sensível a ruídos. O parâmetro  $h$  controla a dispersão da

matriz de covariância  $K = hI$  na função de densidade normal multivariada, determinando a influência dos vizinhos no cálculo da probabilidade: valores grandes de  $h$  fazem com que a contribuição de cada vizinho se espalhe mais, tornando a decisão mais global, enquanto valores pequenos tornam o modelo mais localizado.

As variáveis  $p_1$  e  $p_2$  representam as somas das densidades de probabilidade para as classes  $-1$  e  $1$ , respectivamente, fornecendo uma medida da influência dos vizinhos de cada classe sobre o ponto de teste. O espaço de projeção formado por  $p_1$  e  $p_2$  permite visualizar como as regiões de decisão são estruturadas no modelo: pontos próximos da diagonal  $p_1 = p_2$  indicam áreas de incerteza, enquanto pontos mais afastados sugerem uma classificação mais confiável.  $k$  maior torna os pontos mais dispersos no espaço de probabilidades, pois considera mais vizinhos, suavizando a separação entre classes. Já  $h$  menor faz os pontos ficarem mais concentrados, pois a função gaussiana tem menos espalhamento, tornando a decisão mais localizada e sensível às variações dos dados.