



Disciplina de Reconhecimento de Padrões - 2025/01  
Exercício sobre Perceptron

Aluna: Raissa Gonçalves Diniz - 2022055823

**Base teórica:**

O Perceptron é um dos algoritmos mais fundamentais em aprendizado de máquina, especialmente no contexto de redes neurais artificiais. Ele foi proposto por Frank Rosenblatt em 1958 e é um classificador linear utilizado para resolver problemas de classificação binária. O modelo do Perceptron é composto por um conjunto de entradas (features), pesos, um viés e uma função de ativação, geralmente uma função de degrau. A principal característica do Perceptron é que ele tenta encontrar uma linha ou plano de separação entre duas classes distintas de dados.

O Perceptron é baseado em uma fórmula simples para calcular a soma ponderada das entradas. Para um dado conjunto de entradas  $x_1, x_2, \dots, x_n$  o Perceptron calcula uma soma ponderada desses valores com os respectivos pesos  $w_1, w_2, \dots, w_n$  mais o viés  $b$ :

$$z = w_1x_1 + w_2x_2 + \dots + w_nx_n + b$$

Em seguida, a função de ativação decide a classe do ponto. No caso do Perceptron simples, a ativação é uma função degrau, que retorna  $+1$  se  $z \geq 0$  e  $-1$  caso contrário. Isso pode ser expresso como:

$$\begin{aligned} y &= +1 \text{ se } z \geq 0 \\ y &= -1 \text{ caso contrário} \end{aligned}$$


A atualização dos pesos ocorre durante o processo de treinamento, quando o Perceptron comete um erro de classificação. Se o Perceptron classificar um ponto de forma incorreta, ele ajusta os pesos e o viés para reduzir o erro. O ajuste dos pesos é feito utilizando a seguinte regra de atualização:

$$w_i \leftarrow w_i + \eta * y * x_i$$

$$b \leftarrow b + \eta * y$$

Onde  $\eta$  é a taxa de aprendizado,  $y$  é a classe real do ponto (1 ou -1) e  $x_i$  é o valor da  $i$ -ésima característica do ponto. O Perceptron continua esse processo de ajuste até que ele consiga classificar todos os pontos corretamente ou até que atinja o número máximo de épocas de treinamento.

### Implementação:



*Figura 1: superfície de separação gerada para o problema*

Em problemas simples como esse, o Perceptron forneceu um bom hiperplano de separação, apesar de não ser a solução ideal. A reta deveria ser um pouco mais inclinada para que novos pontos fossem devidamente classificados com maior certeza.

Para obter um modelo mais robusto, seria interessante considerar a introdução de uma estratégia de regularização que ajude a otimizar o alinhamento da reta de separação. Além disso, em problemas mais complexos, onde as classes não são linearmente separáveis, o Perceptron pode não ser suficiente, e outras técnicas seriam mais eficazes.